

Transkryptomika

Opcja 3- Analiza bulk RNA-seq (drugorzędowa)

Lena Borowiecka

Analizę danych bulk RNA-seq rozpoczęto od przygotowania macierzy zliczeń genów. Dane pochodziły z programu *featureCounts* i obejmowały próbki należące do dwóch grup: WT (typ dziki) oraz MUT (mutant).

Dane wczytano do środowiska R i na ich podstawie utworzono macierz zliczeń, w której wiersze odpowiadały genom, a kolumny próbom biologicznym. Geny zidentyfikowano za pomocą stabilnych identyfikatorów ENSEMBL. Próbki przypisano do grup WT i MUT na podstawie nazw kolumn.

W celu ułatwienia interpretacji biologicznej przeprowadzono adnotację genów z użyciem pakietu *biomaRt*, uzyskując m.in. symbole genów, informacje genomowe oraz opisy funkcjonalne.

Następnie utworzono obiekt *DESeqDataSet* przy użyciu pakietu *DESeq2*, zawierający macierz zliczeń, informacje o próbkach oraz schemat eksperymentalny. Obiekt ten stanowił podstawę do dalszej analizy różnicowej ekspresji genów. Obiekt zawiera: 2992 geny (wiersze), 6 próbek (kolumny), informacje o warunkach próbek, surowe zliczenia fragmentów RNA-seq.


Zadanie 1

Zastosowanie funkcji `length(which(fr1$padj < 0.05))` pozwoliło na zidentyfikowanie 296 genów, które wykazują istotne zmiany w ekspresji między grupą zmutowaną (MUT) a kontrolną (WT). Wykorzystanie wartości `padj` (adjusted p-value) zamiast surowego p-value jest niezbędne w analizach wielkoskalowych, aby zminimalizować ryzyko wystąpienia wyników fałszywie dodatnich wynikających z wielokrotnego testowania tysięcy genów jednocześnie.

Interpretacja rozkładów


- **Histogram p-value:** Wykazuje pożądany kształt z wyraźnym pikiem w pobliżu zera. Świadczy to o obecności silnego sygnału biologicznego w danych – wiele genów reaguje na wprowadzoną zmianę (mutację).

Histogram of fr1\$pvalue




- **Histogram padj:** Prezentuje efekt korekty statystycznej. Choć liczba genów istotnych ulega zmniejszeniu w porównaniu do surowych wyników, grupa 296 genów pozostaje oddzielona, co pozwala na ich bezpieczną interpretację funkcjonalną.

Histogram of fr1\$padj



- **Histogram log2FoldChange:** Rozkład informuje o wielkości i kierunku zmian. Większość genów skupia się wokół zera (brak zmiany), co jest typowe dla precyzyjnych modeli biologicznych. Obecność genów wykresu osiągających wartości powyżej 5 i poniżej -5 wskazuje na istnienie grupy transkryptów o silnej reakcji na mutację.




Integracja danych i transformacja logarytmiczna

Pierwszym krokiem jest połączenie wyników testu Wald (obiekt `fr1`) z wcześniej przygotowaną tabelą adnotacji `gen`. Dzięki operacji mapowania (`match`), identyfikatory ENSEMBL zostały wzbogacone o symbole genów (HGNC), opisy biologiczne oraz numery Entrez ID.

Kolejnym etapem jest przygotowanie macierzy znormalizowanych zliczeń (`normalized=TRUE`), co pozwala na porównywanie poziomów ekspresji między próbkami o różnej głębokości sekwencjonowania. Aby zapobiec utracie danych, zastosowano skuteczną metodę polegającą na dodaniu tzw. pseudozliczenia (pseudocount), czyli przesunięciu wszystkich wartości o 1 przed logarytmowaniem ($\log_2(df+1)$). Taka operacja pozwala na zachowanie wszystkich obserwacji: Wartości zerowe zostają przekształcone w zera w skali logarytmicznej. Poprawę czytelności wykresów: Histogram danych po transformacji logarytmicznej wykazuje znacznie bardziej zrównoważony rozkład, co ułatwia biologiczną interpretację poziomów ekspresji.

Zadanie 2


Podstawowy wykres, zestawiający skorygowaną wartość p-value (`padj`) z logarytmem zmiany ekspresji (`log2FoldChange`), jest mało czytelny, ponieważ najbardziej istotne geny skupiają się przy dolnej krawędzi osi rzędnych. Standardową praktyką jest zastosowanie transformacji $-\log_{10}$ dla wartości `padj`. Dzięki temu geny o najniższych (najbardziej istotnych) wartościach p-value wędrują na szczyt wykresu. Wykres przyjmuje symetryczny kształt.



Podczas tworzenia wykresów zaobserwowano występowanie wartości *padj* równych zero, co stanowi efekt ograniczonej precyzji obliczeń numerycznych, a nie rzeczywistą wartość statystyczną. Problem ten wpływa na wizualizację danych, ponieważ prowadzi do wartości nieskończonych, które nie są uwzględniane na wykresach. Aby temu zapobiec, wartości zerowe zastąpiono małą dodatnią liczbą, co umożliwiło ich poprawne przedstawienie i zachowanie najbardziej istotnych genów na wykresie.

W celu zwiększenia wartości informacyjnej wykresu, naniesiono na niego dodatkowe oznaczenia:

Kolor czerwony (zmienna *w*): Wyróżnia geny uznane za istotne statystycznie ($\$padj < 0,05$).



Zidentyfikowano geny o co najmniej pięciokrotnie podwyższonej ekspresji w grupie MUT. Geny te, zlokalizowane w prawym górnym obszarze wykresu, uznano za potencjalne biomarkery najsilniej związane z badaną zmianą eksperymentalną.

Analiza głównych składowych (PCA) wykonana po transformacji logarytmicznej ze stabilizacją wariancji (**rlog**) wykazała:

Separacja grup: Próbkę z grupy zmutowanej (MUT) oraz typu dzikiego (WT) rozdzielają się całkowicie wzdłuż pierwszej głównej składowej (PC1). Świadczy o tym, że mutacja jest głównym czynnikiem determinującym różnice w transkryptomie.

Homogenność wewnątrz grup: Próbkę WT wykazują bardzo niskie rozproszenie, co sugeruje wysoką powtarzalność biologiczną i techniczną. Grupa MUT jest nieco bardziej zróżnicowana, co może wynikać z indywidualnej odpowiedzi organizmów na badaną zmianę.

Analiza PCA przeprowadzona bezpośrednio na genach (**prcomp**) dostarcza informacji o dominacji głównego trendu: Pierwsza składowa główna genów wykazuje bardzo wysokie odchylenie standardowe, co sugeruje, że większość genów podąża za jednym, silnym wzorcem zmian wywołanym przez mutację.


Zestawienie istotności statystycznej z wielkością zmiany ekspresji przy użyciu pakietu **EnhancedVolcano**: **Wiarygodność statystyczna:** Rozkład wartości p-value wykazuje kształt z wyraźną dominacją niskich wartości, co potwierdza obecność silnego sygnału biologicznego. **Kluczowe geny:** Narzędzie **EnhancedVolcano** automatycznie

zidentyfikowało najbardziej zmienione geny, takie jak ENSG00000105509 oraz ENSG00000174652.

Zadanie 3

Volcano plot

EnhancedVolcano



Proces zamiany identyfikatorów oparto na mapowaniu (**match**) nazw z tabeli wyników **res2** do bazy adnotacji **gen**. Operacja ta pozwoliła na:

- Oczyszczenie zbioru: Usunięcie genów bez przypisanych nazw symbolicznych przy użyciu funkcji **is.na(m)**.
- Adnotację symboliczną: Przypisanie czytelnych nazw (np. **C3**, **ZNF845**, **SSC5D**) do wierszy macierzy **res3**.

Obserwacje z wykresu:

- Góra wykresu (najwyższa istotność): Geny takie jak **SSC5D**, **SLC25A23** oraz **C3** wykazują najwyższą istotność statystyczną ($-\log_{10} P > 30$), co czyni je najbardziej wiarygodnymi biomarkerami różniącymi grupę MUT od WT.
- Prawa strona : Gen **ZNF845** wyróżnia się ekstremalnie wysoką zmianą ekspresji, co sugeruje jego kluczową rolę w odpowiedzi na badaną mutację.
- Lewa strona (silna supresja): Geny takie jak **ZNF266** oraz **SEMA6B** wykazują istotnie obniżoną ekspresję w grupie MUT.

Podsumowanie analizy wzbogaceń funkcjonalnych dla różnicowo ekspozowanych genów

Analiza została przeprowadzona w celu biologicznej interpretacji genów wykazujących istotne zmiany w ekspresji między grupami MUT i WT. Proces ten pozwala powiązać listę genów z konkretnymi funkcjami molekularnymi, procesami biologicznymi i komponentami komórkowymi.

Najistotniejsze procesy biologiczne (BP)

Zidentyfikowano 16 wzbogaconych terminów GO. Do procesów o najwyższym poziomie istotności statystycznej (najniższe **p.adjust**) należą:

- Oczyszczanie z amyloidu-beta (amyloid-beta clearance): Proces o największej istotności ($p.adjust \approx 0,0048$), w który zaangażowanych jest 7 genów z listy.
- Szlak sygnałowy receptorów dopełniacza (complement receptor mediated signaling pathway): Istotny statystycznie szlak angażujący 5 genów.
- Składanie cząstek lipoprotein HDL (high-density lipoprotein particle assembly): Proces angażujący 4 geny.

Komponenty komórkowe (CC) i liczność genów


Wykres słupkowy pokazuje, że największa liczba genów jest powiązana ze strukturami błonowymi odpowiedzialnymi za transport i degradację:

- Błona lizosomalna i błona wakuoli litycznej: Każda z tych kategorii obejmuje po 15 genów.
- Błona granulek wydzielniczych: Zaangażowanych jest 12 genów.
- Mimo dużej liczby genów, kategorie te mają wyższe wartości **p.adjust** (kolor niebieski) w porównaniu do procesów immunologicznych (kolor czerwony).

Analiza wskazuje, że badana mutacja wpływa przede wszystkim na odpowiedź immunologiczną (dopełniacz, cytotoksyczność komórek NK) oraz metabolizm lipidów i amyloidu. Wyraźne wzbogacenie genów związanych z błonami lizosomów sugeruje również istotne zmiany w wewnątrzkomórkowym transporcie i degradacji białek.

Zadanie 4

Celem tej analizy było zidentyfikowanie procesów biologicznych (Biological Process - BP), które uległy aktywacji lub wzmocnieniu w wyniku badanej mutacji.



Najistotniejsze ścieżki sygnałowe:

Na podstawie wyników liczbowych oraz wykresu słupkowego, zidentyfikowano kluczowe procesy:

- Szlak sygnałowy receptorów dopełniacza (GO:0002430): Jest to najbardziej istotny statystycznie proces ($\$p.adjust = 0,000198\$$), angażujący 5 kluczowych genów. Wysoki wskaźnik *Fold Enrichment* (41.25) sugeruje, że mutacja drastycznie aktywuje kaskadę dopełniacza, co jest typowe dla stanów zapalnych.
- Oczyszczanie z amyloidu-beta (GO:0097242): Drugi pod względem istotności proces ($\$p.adjust = 0,0086\$$), również z udziałem 5 genów. Chromosom 19 jest znany z obecności genów takich jak *APOE* czy *CD33*.
- Sygnalizacja GPCR aktywująca fosfolipazę C (GO:0007200): Istotny statystycznie szlak ($\$p.adjust = 0,04\$$), angażujący 7 genów. Proces ten odpowiada za wewnątrzkomórkowe przekazywanie sygnałów, co może wskazywać na pobudzenie metaboliczne komórek zmutowanych.

Wykres słupkowy pozwala na wizualną ocenę rozkładu funkcji genów:

- Liczność genów (Count): Najwięcej genów podwyższonych bierze udział w regulacji odpowiedzi immunologicznej poprzez receptory powierzchniowe (10 genów) oraz w procesach wirusowych (9 genów).
- Istotność (Kolorystyka): Dominacja koloru czerwonego i fioletowego na szczycie wykresu wskazuje, że procesy immunologiczne (dopełniacz, amyloid) mają najwyższą wiarygodność statystyczną, podczas gdy procesy wirusowe czy migracja leukocytów (kolor niebieski) wykazują słabsze, choć wciąż zauważalne wzbogacenie.